

Otimização Cooperativa de Hiperparâmetros em Ensembles Heterogêneos para Séries Temporais

Filipe Cordeiro de Medeiros Azevedo

Universidade de Pernambuco (UPE)

Recife, Pernambuco

fcma@ecom.poli.br

Abstract—Este trabalho propõe um algoritmo cooperativo coevolutivo para a otimização conjunta dos hiperparâmetros de modelos heterogêneos aplicados à previsão de séries temporais. A abordagem combina os modelos ARIMA, SVR e MLP em um ensemble, no qual cada modelo evolui em uma população distinta e é avaliado em um contexto colaborativo, considerando simultaneamente o desempenho preditivo e a diversidade entre os modelos. Dois mecanismos de seleção foram comparados: seleção por torneio e seleção aleatória. Os experimentos realizados com o conjunto de dados *Air Passengers* indicaram que a seleção por torneio resulta em ensembles mais precisos e estáveis. A inclusão de uma métrica explícita de diversidade contribuiu para a geração de modelos complementares e evitou a convergência prematura.

Index Terms—Algoritmos Cooperativos Coevolutivos; Diversidade; Séries temporais.

I. INTRODUÇÃO

A previsão de séries temporais desempenha um papel crucial em diversas áreas como finanças, energia e saúde, onde decisões estratégicas dependem da capacidade de estimar com precisão o comportamento futuro de variáveis ao longo do tempo. Métodos tradicionais como o ARIMA são amplamente utilizados por sua eficácia em capturar padrões lineares, mas mostram limitações frente à complexidade dos dados contemporâneos, que frequentemente apresentam não linearidades, sazonalidades múltiplas e ruídos estruturados [1].

Nesse cenário, modelos híbridos ou ensembles compostos por diferentes tipos de preditores têm se destacado como alternativas promissoras. A combinação de ARIMA, SVR (Support Vector Regression) e MLP (Multi-Layer Perceptron) permite integrar distintas formas de representação: o ARIMA modela dependências lineares, o SVR capta relações não-lineares suaves e o MLP aprende padrões complexos e altamente não-lineares [2].

Um dos principais desafios para o sucesso dessa abordagem está na seleção e ajuste dos hiperparâmetros de cada modelo base. Essa etapa é determinante para a capacidade de generalização e o desempenho preditivo geral. Algoritmos evolutivos, como os Algoritmos Genéticos (GA) e os Algoritmos Cooperativos Coevolutivos (CCEA), têm demonstrado grande eficácia na exploração de espaços de busca complexos, superando limitações de abordagens exaustivas tradicionais e adaptando-se melhor às características do problema [3]. A utilização de um esquema de coevolução cooperativa permite que populações distintas, representando diferentes modelos

base, evoluam de maneira coordenada, favorecendo interações que promovem não apenas a melhoria individual, mas também a complementaridade entre os modelos [4].

Nesse contexto, a diversidade entre os preditores do ensemble emerge como uma propriedade desejável. Estudos indicam que conjuntos compostos por modelos com diferentes características estruturais e comportamentais tendem a apresentar melhor desempenho global, sobretudo em cenários marcados por padrões heterogêneos nos dados [5].

A relação entre diversidade e generalização também tem sido objeto de investigação em ambientes coevolutivos, onde populações especializadas colaboram de forma eficaz para explorar diferentes regiões do espaço de busca e ampliar o desempenho coletivo do sistema [6].

Este trabalho propõe um algoritmo cooperativo coevolutivo para otimização conjunta dos hiperparâmetros de modelos heterogêneos aplicados à previsão de séries temporais. A abordagem busca equilibrar acurácia e diversidade por meio da evolução coordenada de populações distintas representando ARIMA, SVR e MLP, incorporando uma métrica de diversidade como critério adicional no processo evolutivo. A eficácia do método é demonstrada por meio de experimentos no conjunto de dados *Air Passengers*, evidenciando ganhos em desempenho preditivo e robustez frente a abordagens tradicionais e não cooperativas.

II. TRABALHOS RELACIONADOS

A construção de ensembles tem se mostrado uma estratégia eficaz para melhorar a robustez e a acurácia de sistemas preditivos. No contexto da previsão de séries temporais, a combinação de modelos com diferentes capacidades de representação permite capturar múltiplos padrões presentes nos dados, como tendências lineares, sazonalidades e comportamentos não-lineares. No entanto, a simples agregação de preditores não garante um bom desempenho coletivo. A literatura aponta que a diversidade entre os modelos é um fator crítico para o sucesso de um ensemble, influenciando diretamente a capacidade do sistema em generalizar para dados não vistos [5].

Diferentes abordagens foram propostas para promover diversidade em conjuntos de modelos, incluindo o uso de dados de treino distintos, inicializações aleatórias, variações na arquitetura dos modelos e, mais recentemente, a aplicação de métodos evolutivos. No caso de sistemas baseados em

aprendizado de máquina, a diversidade pode ser explorada como uma dimensão adicional da otimização, sendo incorporada diretamente à função objetivo do processo evolutivo. Essa estratégia permite selecionar subconjuntos de modelos que, embora individualmente menos performáticos, oferecem complementariedade ao ensemble como um todo [7].

Nesse contexto, algoritmos cooperativos coevolutivos têm ganhado destaque por sua capacidade de explorar múltiplas subpopulações em paralelo, promovendo tanto especialização quanto cooperação. Ao dividir o problema em componentes e atribuir a cada população a responsabilidade por um aspecto específico da solução, como os hiperparâmetros de um determinado modelo base, o algoritmo é capaz de otimizar soluções parciais que quando combinadas, resultam em um desempenho superior. Essa abordagem é especialmente vantajosa em tarefas de previsão complexas, nas quais múltiplos modelos interagem de forma não trivial [4].

A literatura também sugere que a introdução de mecanismos explícitos de avaliação da diversidade entre os indivíduos das subpopulações pode ampliar os benefícios da coevolução cooperativa. Estudos em ambientes competitivos e colaborativos mostram que a diversidade não apenas previne a convergência prematura, mas também aumenta a capacidade de adaptação do sistema, promovendo soluções mais generalizáveis e resilientes a ruídos ou variações estruturais nos dados [6].

Este trabalho se insere nessa linha de pesquisa ao propor uma estratégia de coevolução cooperativa voltada à otimização de hiperparâmetros de modelos heterogêneos para previsão de séries temporais. Diferentemente de abordagens anteriores, a proposta incorpora uma métrica explícita de diversidade como parte do critério de avaliação durante a evolução das subpopulações, buscando equilibrar acurácia individual e complementariedade entre os modelos.

III. METODOLOGIA

A. Conjunto de Dados

Os experimentos foram conduzidos com o conjunto de dados clássico *Air Passengers*, que contém observações mensais do número de passageiros de uma companhia aérea internacional entre 1949 e 1960. Este conjunto é amplamente utilizado como benchmark em tarefas de previsão de séries temporais por apresentar padrões sazonais e tendência de crescimento, características que o tornam adequadas para avaliar modelos com diferentes capacidades de representação.

A série foi inicialmente normalizada e, em seguida, dividida em três subconjuntos: 70% das observações foram destinadas ao treinamento dos modelos, 15% foram utilizadas como conjunto de validação e os 15% restantes compuseram a base de teste. Essa divisão foi realizada de forma sequencial, respeitando a ordem temporal dos dados, com o objetivo de preservar a estrutura temporal da série e evitar vazamentos de dados. O conjunto de validação foi utilizado exclusivamente para a avaliação intermediária dos indivíduos durante o processo evolutivo, enquanto o conjunto de teste foi reservado para a avaliação final do ensemble gerado.

B. Modelos Base

Para estruturar a tarefa de previsão, os modelos foram configurados para utilizar todo o histórico disponível até o ponto de corte da previsão e estimar os valores correspondentes aos 12 meses seguintes. Essa abordagem, comum em contextos de séries temporais, visa avaliar a capacidade dos modelos em projetar tendências, padrões sazonais e flutuações a médio prazo, com base no conhecimento acumulado do passado.

Essa configuração foi aplicada igualmente aos três modelos base: ARIMA, SVR e MLP. Essa abordagem garantiu que todos os modelos operassem com o mesmo contexto. O ARIMA foi ajustado diretamente sobre a série temporal histórica, enquanto o SVR e o MLP foram treinados com estruturas supervisionadas do histórico acumulado, de modo a gerar previsões multivariadas para o horizonte de 12 passos à frente. A uniformidade na definição da tarefa permite comparações diretas de desempenho e viabiliza a integração dos modelos no ensemble.

C. Algoritmo Cooperativo Coevolutivo

A proposta central deste trabalho é um algoritmo cooperativo coevolutivo para otimização conjunta dos hiperparâmetros dos modelos ARIMA, SVR e MLP no contexto de previsão de séries temporais. A abordagem baseia-se na ideia de coevolução entre populações distintas, cada uma responsável pela evolução dos parâmetros de um modelo específico. Essa estratégia permite que os modelos se especializem de forma independente, ao mesmo tempo em que são avaliados de maneira colaborativa com o objetivo de compor um ensemble mais eficaz.

O algoritmo mantém três populações paralelas, associadas respectivamente ao ARIMA, SVR e MLP. Cada indivíduo em uma população representa uma configuração possível de hiperparâmetros para o modelo correspondente. A cada geração, uma combinação dos três melhores indivíduos das diferentes populações são formadas para compor ensembles temporários, cuja performance é avaliada com base em uma função objetivo composta por duas métricas: desempenho preditivo e diversidade. A pontuação final de cada indivíduo reflete seu desempenho individual e sua diferença média em relação às previsões dos indivíduos das populações parceiras.

A função de desempenho é dada por $\frac{1}{(RMSE + \varepsilon)}$, onde ε é uma constante de valor muito pequeno adicionado para evitar divisões por zero. Essa métrica busca maximizar o desempenho preditivo ao penalizar erros quadráticos médios elevados. Para incentivar a diversidade entre os modelos base, foi incorporada uma segunda métrica à função objetivo, baseada na distância entre a previsão do indivíduo avaliado e a mediana das diferenças das previsões dos indivíduos das demais populações. Especificamente, é utilizado o erro quadrático médio (MSE) entre essas previsões, de modo a capturar o grau de independência e complementariedade do indivíduo em relação aos demais componentes do ensemble.

A função objetivo combina essas duas métricas de forma ponderada, com peso de 0,9 atribuído ao desempenho e 0,1

à diversidade. Esse equilíbrio foi escolhido de forma a privilegiar soluções acuradas, mas que também tragam variabilidade útil para o conjunto, evitando a convergência de todos os modelos para comportamentos similares. Ao longo das gerações, operadores evolutivos são aplicados separadamente em cada população, com seleção, recombinação e mutação, com o objetivo de explorar e refinar configurações promissoras nos respectivos espaços de busca.

A principal vantagem dessa abordagem está na sua capacidade de promover especialização local sem perder de vista a exploração global do ensemble. A estrutura modular, aliada à avaliação cooperativa e ao incentivo à diversidade, permite que os modelos evoluam de forma coordenada, contribuindo com perspectivas complementares sobre a série temporal e aumentando a robustez da previsão final.

D. Experimentos

Com o objetivo de avaliar a eficácia do algoritmo cooperativo coevolutivo proposto, foram conduzidos experimentos comparando duas variantes do método: uma utilizando seleção por torneio e outra utilizando seleção aleatória. Ambas as versões seguem a mesma estrutura geral do algoritmo, com três populações paralelas dedicadas à otimização dos hiperparâmetros dos modelos ARIMA, SVR e MLP, avaliação cooperativa e função objetivo composta por desempenho e diversidade. A única diferença entre as variantes reside no mecanismo de seleção utilizado durante a aplicação dos operadores evolutivos.

Na seleção por torneio, grupos aleatórios de indivíduos são formados dentro de cada população, e o indivíduo com melhor pontuação dentro de cada grupo é selecionado para reprodução. Esse método favorece a preservação de soluções com desempenho superior, ao mesmo tempo em que mantém certa pressão seletiva e diversidade populacional. Já na seleção aleatória, os indivíduos são escolhidos sem qualquer critério de mérito, permitindo maior aleatoriedade na recombinação e promovendo a exploração do espaço de busca, ainda que com menor pressão evolutiva.

A avaliação do desempenho das duas variantes é realizada com base em três métricas amplamente utilizadas em tarefas de regressão: o erro quadrático médio (MSE), a raiz do erro quadrático médio (RMSE) e o coeficiente de determinação (R^2). Essas métricas são calculadas sobre o conjunto de teste, permitindo comparar diretamente a acurácia e a qualidade das previsões geradas pelos ensembles resultantes de cada abordagem.

IV. RESULTADOS E DISCUSSÃO

Nesta seção, é apresentado o desempenho das duas variantes do algoritmo cooperativo coevolutivo: uma com seleção por torneio e outra com seleção aleatória. A avaliação é realizada com base em três métricas amplamente utilizadas em tarefas de regressão: o erro quadrático médio (MSE), a raiz do erro quadrático médio (RMSE) e o coeficiente de determinação (R^2). As métricas são calculadas sobre o conjunto de teste,

com o objetivo de quantificar a acurácia e a qualidade das previsões geradas pelos ensembles resultantes.

TABLE I
DESEMPENHO DAS VARIANTES DO ALGORITMO COOPERATIVO COEVOLUTIVO NO CONJUNTO DE TESTE

Método	Métrica		
	RMSE	MSE	R^2
Seleção aleatória	100,73	10146,66	0,14
Seleção por torneio	80,82	6532,56	0,58

Além dos valores médios das métricas de desempenho, a Figura 1 e a Figura 2 ilustram a evolução do *fitness score* ao longo das gerações para as variantes com seleção aleatória e seleção por torneio, respectivamente.




Fig. 1. Evolução da função objetivo (*fitness score*) ao longo das gerações com seleção aleatória. Observa-se alta variabilidade e ausência de tendência clara de convergência.




Fig. 2. Evolução da função objetivo (*fitness score*) ao longo das gerações com seleção por torneio. É possível notar uma tendência clara de melhoria com estabilização nas gerações finais.

As curvas de evolução indicam um comportamento distinto entre as abordagens. A seleção aleatória apresenta flutuações acentuadas ao longo do tempo, com episódios frequentes de queda no desempenho. Em contraste, a seleção por torneio conduz a uma trajetória ascendente mais consistente, com estabilização da função objetivo nas gerações finais. Esse comportamento sugere uma convergência mais eficaz do processo evolutivo, fruto da seleção imposta pelo torneio.

Os resultados numéricos e visuais reforçam a superioridade da seleção por torneio na tarefa considerada. Essa estratégia favorece a retenção de indivíduos com bom desempenho ao longo das gerações, ao mesmo tempo em que preserva diversidade suficiente para evitar máximos locais. Já a seleção aleatória, embora mais exploratória, mostra-se bastante instável e menos eficaz na composição de ensembles com desempenho robusto.

V. CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho apresentou um algoritmo cooperativo coevolutivo para otimização conjunta dos hiperparâmetros de modelos base heterogêneos aplicados à previsão de séries temporais. A abordagem proposta combina os modelos ARIMA, SVR e MLP em um ensemble, utilizando populações evolutivas distintas para cada tipo de modelo e promovendo uma avaliação colaborativa com base em desempenho preditivo e diversidade. Os resultados obtidos demonstraram que a estratégia de seleção por torneio apresenta desempenho superior à seleção aleatória, tanto em termos de qualidade preditiva quanto de estabilidade ao longo das gerações.

A análise quantitativa dos resultados indicou que a seleção por torneio favorece a convergência dos modelos e resulta em ensembles mais alinhados com o comportamento real da série temporal. A inclusão de uma métrica explícita de diversidade contribuiu para evitar a convergência prematura e para promover complementaridade entre os modelos, reforçando a importância da diversidade estrutural em sistemas de previsão cooperativos.

Como trabalhos futuros, destaca-se a necessidade de avaliar a generalização da abordagem em diferentes conjuntos de dados, com características variadas de tendência, sazonalidade e ruído. Além disso, novas definições de diversidade podem ser exploradas, incluindo métricas baseadas na distância entre representações internas ou correlação entre previsões. Outra possibilidade com potencial consiste na experimentação com diferentes composições de modelos base, incorporando arquiteturas de aprendizado profundo ou modelos alternativos de aprendizado de máquina, a fim de investigar o impacto da heterogeneidade estrutural na performance do ensemble.

Esses trabalhos têm o potencial de ampliar a aplicabilidade da abordagem proposta, tornando mais robusta e adaptável a diferentes cenários de séries temporais.

REFERENCES

- [1] G. Mahalakshmi, S. Sridevi, and S. Rajaram, "A survey on forecasting of time series data," in *2016 international conference on computing technologies and intelligent data engineering (ICCTIDE'16)*. IEEE, 2016, pp. 1–8.
- [2] J. F. L. de Oliveira and T. B. Ludermir, "A hybrid evolutionary system for parameter optimization and lag selection in time series forecasting," in *2014 Brazilian Conference on Intelligent Systems*. IEEE, 2014, pp. 73–78.
- [3] V. Tormozov, A. Zolkin, and K. Vasilenko, "Optimization of neural network parameters based on a genetic algorithm for prediction of time series," in *2020 International Multi-Conference on Industrial Engineering and Modern Technologies (FarEastCon)*. IEEE, 2020, pp. 1–4.
- [4] X. Ma, X. Li, Q. Zhang, K. Tang, Z. Liang, W. Xie, and Z. Zhu, "A survey on cooperative co-evolutionary algorithms," *IEEE Transactions on Evolutionary Computation*, vol. 23, no. 3, pp. 421–441, 2018.
- [5] Z. Gong, P. Zhong, and W. Hu, "Diversity in machine learning," *Ieee Access*, vol. 7, pp. 64 323–64 350, 2019.
- [6] S. Y. Chong, P. Tino, and X. Yao, "Relationship between generalization and diversity in coevolutionary learning," *IEEE Transactions on computational intelligence and AI in games*, vol. 1, no. 3, pp. 214–232, 2009.
- [7] C. Smith and Y. Jin, "Evolutionary multi-objective generation of recurrent neural network ensembles for time series prediction," *Neurocomputing*, vol. 143, pp. 302–311, 2014.